NVIDIA NETWORKING • TECHNICAL GUIDE

ConnectX-6 网卡 RoCEv2 拥塞控制与 PFC 流控实施指南

基于 NVIDIA 官方文档的 DCQCN / ECN / PFC 设计、配置、验证与运维

17 份 NVIDIA 官方文档 · DCQCN / ECN / PFC · 含命令、验收与排障

适用对象

网络架构师、RDMA / RoCE 运维工程师、AI/HPC 集群交付与测试人员

适用型号

ConnectX-6 EN / ConnectX-6 VPI 的 Ethernet 模式；ConnectX-6 Dx/Lx 请按对应固件文档复核参数

版本	日期	文档状态
v1.1	2026-10-25	技术整理稿 · 实施前按环境复核

本文件为公开 NVIDIA 文档的工程整理，不替代 NVIDIA 官方技术支持或现场验证。

文档信息

项目	内容
文档名称	ConnectX-6 网卡 RoCEv2 拥塞控制与 PFC 流控实施指南
副标题	基于 NVIDIA 官方文档的 DCQCN / ECN / PFC 设计、配置、验证与运维
版本 / 日期	v1.1 / 2026-10-25
证据基线	17 份 NVIDIA 官方文档（详见附录 D），访问日期 2026-10-25
适用范围	ConnectX-6 Ethernet / RoCEv2；Linux 主机；NVIDIA Onyx 或 Cumulus Linux 交换机示例
不适用范围	InfiniBand 模式的 credit/IB CC；Windows/WinOF-2 的注册表配置；非 NVIDIA 交换机的厂商私有实现
维护建议	每季度或固件/驱动升级后复核一次；参数与默认值以设备 query 输出为准

阅读说明与证据等级

本文把“官方事实”“官方默认/示例”“工程建议”分开写。正文中的 [S1]–[S17] 对应附录 D 的 NVIDIA 官方文档；没有引用的操作性建议，均明确标注为“工程建议”，代表基于机制的落地方法，不是 NVIDIA 强制规范。

等级	含义	在本文中的标记
官方事实	可直接在 NVIDIA 文档中找到原文的能力、协议行为、限制条件。	文中以 [S#] 标注
官方默认/示例	NVIDIA 产品文档给出的默认值、示例配置或参考拓扑；会随版本/平台变化。	文中写“默认/示例”，并提示复核
工程建议	为实现可运维、可验证的部署而给出的做法；不是协议强制。	文中写“建议/应/不要”，并解释依据
工程公式	用于量级校验的推导公式，不能替代厂商缓冲计算。	文中明确标注“工程校验”

目录

章	内容	章	内容
1	执行摘要	9	验证、验收与性能测试
2	范围、术语与证据方法	10	运维监控、故障排查与应急
3	CX6 的能力边界与机制定位	11	风险、限制与回滚
4	RoCEv2 拥塞控制：ECN 与 DCQCN	12	结论与检查清单
5	DCQCN 参数、默认值与调优	A	附录 A 命令速查
6	PFC 流控：原理、缓冲与阈值	B	附录 B DCQCN 参数总表
7	端到端设计：优先级、PFC 域与 ECN 域	C	附录 C 官方原文证据摘录
8	实施步骤：从基线到上线	D	附录 D 参考文档与链接

如何使用本文

第一次部署：按第 3→7 章做设计，再按第 8 章实施，最后按第 9 章验收。已经在线运行的集群：直接看第 5、6、10 章的调优与排障。需要给评审/审计看依据：看第 2 章的证据方法、附录 C 的原文摘录和附录 D 的链接。

1 执行摘要

这份文档回答三个问题：ConnectX-6 上的 RoCEv2 拥塞控制与 PFC 分别是什么、应该如何端到端配置、上线后如何证明它真的生效。结论建立在 NVIDIA 公开文档之上；凡是超出文档原文的工程做法，文中都会明确标注。

1.1 结论先行

结论	要点	依据
PFC 与 DCQCN 不是替代关系	PFC 是逐跳、逐优先级的链路反压；DCQCN 是端到端、基于 ECN/CNP 的速率控制。前者防瞬时溢出，后者防持续拥塞。	[S3][S5][S8]
RoCEv2 有两条合法路线	Lossless：PFC + ECN/DCQCN；Lossy：只靠 ECN/DCQCN + 传输层重传。选哪条由业务对丢包/时延的容忍度决定。	[S10][S13]
NVIDIA 常见默认值不是协议强制值	RoCE 常用 priority 3 / DSCP 26，CNP 常用 DSCP 48 / PCP 6；Onyx 默认 ECN 150–1500 KB（150 KB–1.5 MB），Cumulus 写作 150000/1500000 字节，量级一致但显示单位不同。数值必须端到端一致，不能只看单台设备。	[S6][S10][S12][S13][S17]
PFC 的成败在缓冲与水线	Xoff 之前要有足够 headroom 吸收在途报文；cable length、MTU、速率、Xoff/Xon 任一错配，都会表现为“配了 PFC 仍然丢包”或“PFC 频繁触发”。	[S9][S12]
CNP 必须被优先转发	接收端网卡生成 CNP 回送源端；CNP 被丢、被 pause、或被排到数据后面，DCQCN 就会失效或过冲。	[S5][S6][S10]
持久化要单独设计	mlxconfig 的固件参数可跨重启保留；PFC/trust/ECN sysfs 等运行时配置通常需要在每次启动后重新应用。	[S14][S15]

1.2 推荐实施路线

1. **定模式**：业务能否容忍重传/乱序？不能 → lossless（PFC+ECN）；能 → lossy（ECN）；只在边缘吸收微突发 → semi-lossless。
2. **定优先级**：RoCE 数据、CNP、普通流量分开；把 RoCE 放到独立 lossless priority，CNP 放 strict priority。
3. **定基线**：记录固件/驱动、`mlxconfig query`、`mlnx_qos`、交换机 `show roce` 和关键计数器。
4. **先固件、再交换机、后主机**：固件参数（CC 优先级、CNP DSCP/PCP）需要重启；交换机与主机运行时配置在维护窗口内落地。
5. **用 incast 验收**：单流只能证明“能跑”，多打一才能证明 PFC/ECN 真正工作。
6. **把配置做成启动项**：PFC、trust、ECN、sysfs 参数纳入 systemd/Ansible/Network Operator，重启后自动复核。

1.3 三条红线

不要做的事

① 不要只在一端开 PFC；② 不要把 RoCE 和普通 TCP 放在同一个 lossless priority；③ 不要在未确认 CNP 优先级和 ECN 阈值前，靠调大 PFC Xoff 硬扛拥塞。前两条会造成“看似 lossless、实际丢包/风暴”，第三条会把拥塞变成大面积反压。

- 不要用 PFC 代替带宽规划：PFC 只能把压力反压回上游，不能创造带宽。
- 不要把 Onyx 的 150/1500 直接当成字节数，也不要把 Cumulus 的 150000/1500000 直接套到所有平台；先确认单位和 TC。
- 不要在生产窗口直接改 `LINK_TYPE`、RoCE 模式或 `mlxconfig` 后不重启；这些操作可能中断业务。
- 不要忽略 `tx_pause_storm_*`、`no-buffer-discard`、`out_of_sequence` 这些“已经在报警”的信号。

1.4 适用读者与阅读路径

角色	优先阅读	关注点
网络架构师	第 3、6、7 章	确定 lossless/lossy、优先级、PFC 域与缓冲策略
交付/实施工程师	第 8、9 章 + 附录 A	按步骤配置、验收、留档
运维/SRE	第 5、10、11 章	监控、排障、变更与回滚
评审/审计	第 2 章 + 附录 C/D	核对每条结论的官方依据

2 范围、术语与证据方法

本文讨论的是 Ethernet 模式下的 RoCEv2。ConnectX-6 也支持 InfiniBand；IB 使用基于信用的链路流控和 IB 拥塞控制，不使用 Ethernet PFC/ECN。把本文的 PFC 命令套到 IB 端口上，不会得到预期的 lossless 行为。

2.1 适用范围

边界	说明
适用	ConnectX-6 EN / VPI 的 Ethernet 模式；RoCEv1/v2 的 Ethernet 承载；Linux OFED/DOCA-OFED；NVIDIA Onyx / Cumulus Linux 的 RoCE 配置示例。
可参考	ConnectX-6 Dx / Lx 的同类机制；但本文的型号能力与默认值证据主要来自 ConnectX-6 文档，使用前必须用对应型号的固件文档复核。
不适用	InfiniBand credit/IB CC；Windows/WinOF-2 注册表；非 NVIDIA 交换机的私有 PFC/ECN 实现；应用层拥塞控制（如 TCP BBR）。
必须复核	固件版本、驱动版本、交换机 NOS 版本、端口速率、MTU、线缆长度、是否启用 DCBX、是否 SR-IOV。

2.2 术语表

术语	含义	依据
PFC	Priority Flow Control，IEEE 802.1Qbb；按 802.1p 优先级独立暂停/恢复的链路流控。	[S3][S8]
ECN	Explicit Congestion Notification，RFC 3168；用 IP 头 2 bit 标记拥塞，不丢包。	[S4][S10]
CNP	Congestion Notification Packet；接收端看到 CE 标记后回送源端的拥塞通知报文。	[S5]
DCQCN	Data Center Quantized Congestion Notification；NVIDIA 网卡上的 ECN 闭环速率控制算法。	[S5][S7]
CP	Congestion Point，通常是以太网交换机 Egress 队列。	[S5]
NP	Notification Point，接收端网卡；生成 CNP。	[S5]
RP	Reaction Point，发送端网卡；按 CNP 调整 QP 速率。	[S5]
Kmin / Kmax / Pmax	ECN 标记的起始阈值、全标记阈值、最大标记概率。	[S5]
Xoff / Xon	PFC 的暂停/恢复水线；Xoff 触发 Pause，Xon 停止 Pause。	[S8][S9]
Headroom	为 Xoff 之后仍在链路上的报文预留的入口缓冲。	[S9][S12]
PG / TC / SP	Priority Group / Traffic Class / Switch Priority；分别对应入口缓冲组、出口队列、交换机内部优先级。	[S9]
DSCP / PCP	IP 头优先级 / VLAN 标签优先级；L3 与 L2 两种标记方式。	[S2][S17]
DCBX	Data Center Bridging Exchange；用 LLDP 把 PFC/ETS 配置从交换机下发到主机。	[S2][S3]
BDP	Bandwidth-Delay Product，带宽时延积；headroom 估算的核心量。	工程定义
HOL	Head-of-Line blocking，队头阻塞；同一优先级内的一条慢流会挡住后续报文。	工程定义
PFC storm	暂停帧沿路径扩散、缓冲区连锁占满，导致大面积停传。	[S8]

2.3 证据方法

本文只把 NVIDIA 官方文档作为“事实”来源，优先使用产品手册、MLNX_OFED/DOCA 文档、Onyx/Cumulus 用户手册和 MFT 文档。厂商博客、第三方文章只在明显标注时作为背景，不作为参数默认值或命令语义的依据。

来源组	用于本文的内容	文档类型
S1–S4	网卡能力、主机 QoS/PFC/ECN 配置	产品手册 + OFED 用户手册
S5–S7	DCQCN 算法、参数、CC 基础设施	DOCA 文档
S8–S11, S17	交换机 PFC/缓冲/RoCE 行为与默认值	Onyx 用户手册
S12–S13	交换机 RoCE 默认配置、PFC watchdog、ECN	Cumulus Linux 用户手册
S14–S16	固件配置、Network Operator 自动化、计数器路径	MFT / Network Operator / DOCA 文档

所有链接在 2026-10-25 访问。NVIDIA 文档可能要求登录企业支持账号；本文引用的页面均为公开可访问页面。

2.4 版本基线

层	本文基线	复核方法
网卡	ConnectX-6 EN/VPI（Ethernet 模式）	以 `mlxconfig query`、`ethtool -i`、PSID 为准
主机软件	MLNX_OFED 24.10-2.1.8 LTS 或 DOCA-OFED 对应版本	命令语义以本机 `--help` 为准
固件工具	MFT 4.36.0	mlxconfig 需要 mst driver
交换机示例	Onyx 3.10.4800；Cumulus Linux 5.15	不同 NOS 命令不同，不要混用
文档日期	2026-10-25	升级后重新核对默认值

2.5 三个容易混淆的概念

概念	是什么	与本文的关系	依据
QCN（802.1Qau）	Layer 2 拥塞通知，使用 CNM；CX6 手册列有该能力。	不是 RoCEv2 的 DCQCN；不要用 QCN 的配置思路替代 ECN/CNP。	[S1][S5]
DCQCN	Layer 3 ECN + CNP 的端到端速率控制；NVIDIA 网卡硬件实现。	RoCEv2 的主流 CC；依赖交换机 ECN 标记和 CNP 优先转发。	[S5][S7]
PFC	Layer 2 逐跳、逐优先级的暂停/恢复。	不是拥塞控制；不降低发送速率，只把压力反压回上游。	[S8]
IB CC	InfiniBand 的 credit/拥塞控制。	与 Ethernet PFC/ECN 不同栈；VPI 端口切到 IB 后不要套用本文。	工程边界

3 CX6 的能力边界与机制定位

ConnectX-6 是双端口 200Gb/s 级别的 VPI/以太网卡。就本文主题而言，关键不是峰值带宽，而是它同时具备 PFC、ECN、DCQCN 和 QoS 映射能力，并且这些能力分别落在不同的硬件/协议层。

3.1 CX6 与本文相关的能力

能力	说明	依据
以太网速率	1/10/25/40/50/100/200 Gb/s；双端口 QSFP56（具体型号而异）	[S1]
PFC	IEEE 802.1Qbb，按优先级暂停/恢复	[S1]
QCN	IEEE 802.1Qau，Layer 2 拥塞通知（注意不是 DCQCN）	[S1]
ETS / QoS	IEEE 802.1Qaz；端口级 QoS、优先级映射	[S1]
RoCE	IBTA RDMA over Converged Ethernet；支持 L2/L3；利用 DCB 与高级拥塞控制硬件	[S1]
ECN / DCQCN	RoCEv2 的 ECN 标记、CNP 生成/处理、RP 速率调整由网卡硬件参与	[S4][S5]
VPI	同一卡可配置 IB 或 Ethernet；端口模式由 `LINK_TYPE_Px` 决定	[S1]
管理	BMC、MCTP、NC-SI 等（与本文无直接关系）	[S1]

> **型号边界**
> 本文的默认值证据来自 ConnectX-6 EN/VPI 文档。ConnectX-6 Dx/Lx 的 PFC/ECN 机制同属 Ethernet 范畴，但固件参数名、默认值和特性集合可能不同；不要因为“都是 CX6”就直接复制 `mlxconfig` 值。先用 `mlxconfig query` 和对应型号的 release notes 核对。

3.2 一张图看清三个平面



图 1 RoCEv2 中 DCQCN 三角色与 PFC 逐跳反压的关系（根据 [S5][S8][S10] 绘制，概念图非按比例）

这张图要表达的不是“PFC 和 DCQCN 一起工作”这么简单，而是三个不同的平面：

平面	载体	方向	关键约束
数据平面	RoCEv2 数据报文	源端 QP → 交换机 Egress → 目的端 QP	受 PFC 暂停、受 ECN 标记
控制平面	CNP 反馈	目的端 NP → 源端 RP	必须低时延、strict priority、不能被 PFC 误伤
流控平面	PFC Pause/Xon	每一跳的接收侧 → 发送侧	逐跳、逐优先级、不跨路由域提供端到端语义

3.3 PFC 不是拥塞控制

这是全文最重要的一句话。PFC 做的是“我这家门口堵了，你先别发”；它不告诉发送端“应该降到多少”，也不感知整条路径的拥塞。DCQCN 做的是“路径上有拥塞，按 QP 把速率降下来”，它通过 ECN 标记和 CNP 形成闭环。两者解决的是不同时间尺度的问题。

维度	PFC	DCQCN / ECN
作用范围	逐跳链路（L2）	端到端路径（L3）
触发信号	接收侧入口缓冲超过 Xoff	交换机 Egress 队列超过 Kmin，标记 CE
反馈方式	Pause 帧 / Xon 帧	CNP 回送源端
执行者	链路两端 MAC/交换芯片	发送端网卡 RP 的限速器
时间尺度	微秒级、瞬时	数十微秒到毫秒级、持续
主要风险	反压扩散、PFC storm、HOL	阈值/参数不当导致降速过度或不足

Lossless 不等于零丢包

NVIDIA Onyx 文档明确写道：lossless 并不意味着报文绝对不会丢失。PFC 只能降低入口缓冲溢出的概率；如果 headroom 不足、线缆长度配置错误、PFC 被绕过或发生风暴，仍然会丢包。不要把“开了 PFC”当成丢包问题的终点。

3.4 RoCEv1、RoCEv2 与 IB 的区别

- **RoCEv2**：IB 传输层跑在 UDP/IP 上（UDP 4791），可路由；本文的 ECN/DCQCN 讨论以 RoCEv2 为主。[S13]
- **RoCEv1**：IB 传输层直接跑在 Ethernet 上，Layer 2、不可路由；PFC 仍可用于保证 lossless，但 DCQCN 的 ECN/CNP 机制按 RoCEv2 实现来讨论。[S4][S10]
- **IB**：使用基于信用的链路流控和 IB 拥塞控制；没有 Ethernet PFC，也不使用本文的 ECN/DCQCN 参数。VPI 卡切到 IB 后，必须按 IB 文档配置。
- **QCN**：CX6 支持 802.1Qau，但它使用 Layer 2 CNM，不是 RoCEv2 的 CNP；不要把 QCN 的调参当成 DCQCN 调参。[S1][S5]

4 RoCEv2 拥塞控制：ECN 与 DCQCN

RoCEv2 的拥塞控制不是交换机单独完成的。交换机负责“看见拥塞并标记”，接收端网卡负责“把标记变成 CNP”，发送端网卡负责“按 CNP 降速/恢复”。这三段合起来才是 DCQCN。

4.1 ECN 的两个比特与三种角色

ECN 是 IP 协议的扩展，用 Traffic Class 字段中的 2 bit 表示拥塞状态；NVIDIA 的这段实现针对 RoCEv2。它要求路径上所有节点（主机、路由器、交换机）都支持 ECN，否则标记无法端到端传递。[S4]

ECN 位	名称	含义
00	Not-ECT	不支持 ECN 的流量；拥塞时只能丢弃。
01	ECT(1)	支持 ECN；可被交换机标记为 CE。
10	ECT(0)	支持 ECN；可被交换机标记为 CE。
11	CE	已遇到拥塞；接收端看到后生成 CNP。

交换机在 Egress 队列上做标记：队列长度超过 Kmin 后，按概率把 ECT 包改成 CE；到 Kmax 时标记概率达到 Pmax。Cumulus 的默认 RoCE profile 把 Pmax 设为 100%，即在 Kmax 时所有 ECN-capable 包都被标记。标记本身不丢包，但如果拥塞继续，缓冲区最终仍会满，后续报文仍可能被丢弃。[S5][S12]

4.2 DCQCN 的闭环

1. **CP（交换机）**：监控 Egress 队列，按 Kmin/Kmax/Pmax 对经过的 RoCEv2 报文做 CE 标记。[S5]
2. **NP（接收端网卡）**：收到 CE 标记的报文后，由硬件生成 CNP，按 QP 标识回送给发送端；不需要主机 CPU 参与。[S5]
3. **RP（发送端网卡）**：收到 CNP 后更新 α，按 α 和 RPG_GD 做乘法降速；没有 CNP 时按定时器/字节计数器逐步恢复。[S5]
4. **闭环稳定**：降速后队列下降 → 交换机停止标记 → CNP 减少 → RP 逐步升速；如果再次拥塞，循环重复。

注意 CNP 是“按流/QP”反馈的：一个 QP 拥塞，不会让同一网卡上的所有 QP 一起降速。这是 DCQCN 相对全局 pause 的关键优势，也是它必须和 PFC 分开理解的原因。[S5]

4.3 拥塞点：交换机如何标记

DCQCN 的拥塞点通常是交换机 Egress 队列。队列超过 Kmin 后，标记概率线性上升；到 Kmax 达到 Pmax。Kmin 太低会过早降速、吞吐受损；Kmin 太高会让缓冲先被填满，PFC 甚至丢包先发生。Kmax 与 Kmin 的间隔决定标记的“渐进程度”。[S5]

单位陷阱

Onyx 的 `show roce` 默认显示 `Min : 150 / Max : 1500`，单位是 KB（Onyx 命令文档明确 `minimum-absolute`/`maximum-absolute` 以 KB 计），即 150 KB–1.5 MB；Cumulus 的默认 RoCE profile 写的是 150000/1500000 字节，量级相同。两者数字不同，是因为显示单位不同，不是两套相距 1000 倍的阈值。配置前仍要确认 NOS、ASIC、TC 和单位，不能把 150 直接当字节。

NVIDIA 的 Onyx RoCE lossless 默认还把 CNP 放到 TC6 strict、RoCE 数据放 TC3 WRR 50%、其他流量放 TC0 WRR 50%。这是一套“让 CNP 先走”的默认调度，不是所有厂商都必须照搬的固定值。[S10][S11]

4.4 通知点：CNP 如何回送

NP 是接收端网卡。它看到 CE 标记后生成 CNP，CNP 里带有目标 QP，源/目的 IP 与数据流相反。CNP 默认使用 DSCP 48、PCP 6；NVIDIA 文档给的 `MIN_TIME_BETWEEN_CNPS` 默认是 4 µs，用来限制 CNP 的发送频率。[S5][S6]

- CNP 必须走低时延路径。Onyx 默认把它放 TC6 strict；如果 CNP 被排到数据后面，RP 的降速会晚一个队列周期。
- CNP 不应该被 PFC 暂停。NVIDIA 默认只对 RoCE priority 3 开 PFC，CNP 在 priority 6；把 CNP 放进 lossless priority 会引入不必要的反压风险。
- CNP 的 DSCP/PCP 必须与交换机信任模式和映射一致。DSCP 48 在默认映射里落到 SP6；如果你的 fabric 改过映射，需要同步修改 `CNP_DSCP`/`CNP_802P_PRIO`。

4.5 反应点：α、降速与恢复

RP 用 α 表示近期拥塞程度（0–1）。每个 `DCE_TCP_RTT` 周期更新一次：收到 CNP 时 α 向 1 靠近，没有 CNP 时 α 衰减。α 越大，单次降速越多。下面的公式按 NVIDIA 文档的参数语义整理；`g = DCE_TCP_G / 1024`。

```
收到 CNP:     alpha <- (1 - g) * alpha + g
未收到 CNP:   alpha <- (1 - g) * alpha

降速:         CurrentRate <- CurrentRate * (1 - alpha / 2^RPG_GD)
恢复:         CurrentRate <- (CurrentRate + TargetRate) / 2
              TargetRate  <- TargetRate + AI   (Additive Increase)
              TargetRate  <- TargetRate + HAI  (Hyper Increase)
```

默认 `DCE_TCP_G=1019`（约 0.995）、`RPG_GD=11`。按公式直算，α=1 时单次降速比例约为 1/2048；这不是“一次 CNP 就砍一半”，而是依赖持续的 CNP 和 4 µs 的监控窗口小步快跑。把 `RPG_GD` 调小会让分母变小、单次降速更狠；调大则更温和。[S6]

阶段	进入条件	行为
Fast Recovery	当前速率低于 TargetRate，且没有 CNP	向 TargetRate 快速靠拢（通常取当前与目标的平均）
Additive Increase (AI)	定时器或字节计数器连续触发达到 `RPG_THRESHOLD`	TargetRate 按 `RPG_AI_RATE` 增加，谨慎探测

阶段	进入条件	行为
Hyper Increase (HAI)	定时器和字节计数器都达到阈值，路径持续无拥塞	TargetRate 按 `RPG_HAI_RATE` 增加，快速 reclaim 带宽

`CLAMP_TGT_RATE` 控制连续 CNP 期间 TargetRate 是否每次都被拉低；默认关闭。它影响的是恢复速度，不是单次降速幅度。不要在没搞清恢复行为前同时改 `CLAMP_TGT_RATE` 和 `RPG_GD`。[S6]

4.6 默认参数速览

参数	默认	作用
ROCE_CC_PRIO_MASK	Enable（逐优先级）	按优先级启用 DCQCN；255 表示 8 个优先级全开
DCE_TCP_G / dce_tcp_g	1019	α 更新权重（10 bit 定点）
DCE_TCP_RTT / dce_tcp_rtt	1 µs	α 更新周期
RPG_GD / rpg_gd	11	降速指数；越小越狠
RATE_REDUCE_MONITOR_PERIOD	4 µs	CNP 观察窗口
RPG_TIME_RESET	300 µs	升速定时器
RPG_BYTE_RESET	32767 × 64 B ≈ 2 MB	升速字节计数器
RPG_AI_RATE / RPG_HAI_RATE	5 / 50 Mb/s	AI / HAI 步长
RPG_MIN_RATE	1 Mb/s	QP 最低速率
CNP_DSCP / CNP_802P_PRIO	48 / 6	CNP 的 DSCP / PCP
MIN_TIME_BETWEEN_CNPS	4 µs	CNP 最小间隔

4.7 DCQCN 做不到什么

- **不能创造带宽**：持续超配、严重 incast、慢接收端，靠调 ECN 阈值解决不了。
- **不能替代 PFC**：如果业务要求零丢包，ECN 只能降低概率，最终仍需入口缓冲/PFC 兜底。
- **不能感知非 ECN 设备**：路径上有一个不标记 ECN 的瓶颈，DCQCN 就看不到它。[S4]
- **不能修复 CNP 丢失**：CNP 被丢、被 pause、被错误映射，RP 会误以为“路径不拥塞”。
- **不能跨 QP 公平**：DCQCN 按 QP 反馈；大量 QP 的公平性还取决于交换机队列和端点实现。

5 DCQCN 参数、默认值与调优

这一章把“可以调什么”与“先调什么”分开。NVIDIA 的默认值是为通用场景选的，不是为你的 incast 模式选的；但默认值也是最安全的起点。除非有明确的计数器证据，否则不要一上来就改 α 或 RPG_GD。

5.1 参数总表

参数	默认	作用	调整影响 / 风险
ROCE_CC_PRIO_MASK	Enable	按优先级启用 DCQCN。255 = 所有 8 个优先级；按 8 位掩码理解，priority 3 对应 8（bit3），写入前以设备 query 为准。	写成 0 会关闭该优先级 CC；按端口命名时用 `_P1/_P2`。
DCE_TCP_G / dce_tcp_g	1019	α 的 EWMA 权重；10 bit 定点，1019/1024≈0.995。	改变 α 的收敛速度；不要和 RPG_GD 同时调。
DCE_TCP_RTT / dce_tcp_rtt	1 µs	α 更新周期。	调大更平滑但反应慢；调小更敏感但可能抖动。
INITIAL_ALPHA_VALUE	1023	第一次收到 CNP 时的 α 初值。	调低会减弱首次降速；通常保持默认。
RATE_TO_SET_ON_FIRST_CNP	0	首个 CNP 是否强制设定一个速率；0 表示不强制。	非 0 会在首 CNP 直接跳到指定 Mb/s，风险高。
RPG_MIN_DEC_FAC	50%	单次降速的最大比例。	调低更温和；调高更激进。
RPG_MIN_RATE	1 Mb/s	QP 最低速率。	调高避免饿死但可能降不下来；调低可能长时间低吞吐。
RPG_GD	11	降速公式的指数；越小降速越狠。	优先保持默认；确需调整时每次只动 1。
RATE_REDUCE_MONITOR_PERIOD	4 µs	两次降速之间的观察窗口。	调大更平滑但反应慢；调小可能过度反应。
CLAMP_TGT_RATE	Disable	控制连续 CNP 时 TargetRate 的更新方式。	影响恢复速度；具体行为以本机参数说明为准。
RPG_TIME_RESET	300 µs	升速定时器。	调小恢复更快但更易再次拥塞；调大恢复慢。
RPG_BYTE_RESET	32767（64 B 单位，约 2 MB）	升速字节计数器。	调小恢复更快；调大对大流更保守。
RPG_THRESHOLD	1	进入 AI/HAI 前需要的连续触发次数。	调大更保守；默认 1 已很激进。
RPG_AI_RATE	5 Mb/s	AI 阶段每次增加的 TargetRate。	调大恢复快但可能过冲；调小恢复慢。
RPG_HAI_RATE	50 Mb/s	HAI 阶段每次增加的 TargetRate。	调大快速 reclaim 但易造成突发；调小更平滑。
CNP_DSCP	48	CNP 的 IP DSCP。	必须与交换机 trust/映射一致；默认映射到 SP6。
CNP_802P_PRIO	6	CNP 的 VLAN PCP。	L2 trust 时使用；与 DSCP 同时配置可避免模式切换出错。
MIN_TIME_BETWEEN_CNPS	4 µs	CNP 最小发送间隔。	调大减少 CNP 开销但反应慢；调小更敏感但增加控制面压力。

默认值来自 DOCA 3.5 文档，适用 ConnectX-4 及以后；不同固件/驱动可能显示不同默认值。调参前先用 `cat /sys/class/net/<if>/ecn/roce_rp/params/<param>` 或 `mlxconfig query` 读取本机实际值。[S6]

5.2 如何读写 ECN 参数

MLNX_OFED 把 RoCEv2 ECN 的 RP/NP 配置放在 sysfs 下，按设备、端口、优先级组织。启用某个优先级后，才能读写该优先级的参数。[S4]

```
IF=ens1f0np0
P=3


# 1) 启用该优先级的 NP / RP（两端都建议启用，因为两端都可能收发）
echo 1 > /sys/class/net/$IF/ecn/roce_np/enable/$P
echo 1 > /sys/class/net/$IF/ecn/roce_rp/enable/$P


# 2) 确认启用状态
cat /sys/class/net/$IF/ecn/roce_np/enable/$P
cat /sys/class/net/$IF/ecn/roce_rp/enable/$P


# 3) 读取参数（不要盲目写）
cat /sys/class/net/$IF/ecn/roce_rp/params/rpg_gd
cat /sys/class/net/$IF/ecn/roce_rp/params/rpg_ai_rate
cat /sys/class/net/$IF/ecn/roce_np/params/cnp_dscp


# 4) 仅在明确需要时写入；写前记录原值
# echo 11 > /sys/class/net/$IF/ecn/roce_rp/params/rpg_gd
```

> **sysfs 不是持久化配置**
> ECN 的 enable 和 params 通常在驱动重载/重启后回到默认；必须纳入启动脚本或配置管理。写入前先备份原值，写入后用 `cat` 复核。

5.3 调优顺序

1. **先看交换机**：确认 ECN 在正确的 TC 上启用、Kmin/Kmax/Pmax 合理、CNP 走 strict。多数“DCQCN 不工作”其实是交换机没标记或 CNP 没被优先转发。
2. **再看 NP**：确认接收端 ECN enable、CNP 生成计数在增长、CNP DSCP/PCP 与交换机映射一致。
3. **再看 RP**：确认发送端 ECN enable、`ROCE_CC_PRIO_MASK` 覆盖了 RoCE priority、CNP 能被收到。
4. **最后才动 α/速率参数**：先调交换机阈值，再调 RP 的 AI/HAI 或 RPG_GD；一次只动一个变量。
5. **用 incast 验证**：单流通常不足以触发持续 ECN；至少 4:1、8:1 的多打一，才能稳定看到 CNP 和降速。
6. **保留基线**：记录调参前后的吞吐、P99 时延、ECN 标记率、PFC pause、`out_of_sequence`。

5.4 症状与参数方向

症状	可能原因	优先动作	注意
吞吐低，ECN 标记率很高	Kmin 太低 / Pmax 太高 / RP 降速过狠	先抬高 Kmin 或降低 Pmax；再看 `RPG_GD` 是否过小。	不要直接关 ECN，否则拥塞会转成丢包/PFC。
吞吐低，ECN 标记率很低	Kmin 太高 / 交换机未标记 / CNP 未生成	查交换机 TC、ECN 开关、NP enable；不要先调 RP。	标记率低但 PFC 高，说明 PFC 在替 ECN 干活。
PFC pause 频繁，ECN 标记少	PFC Xoff 太低 / ECN Kmin 太高 / 微突发	先确认是否微突发；再评估抬高 Xoff、降低 Kmin。	不要把 Xoff 无限抬高，会挤占 headroom。
PFC pause 不多，但仍有丢包	headroom 不足 / cable length 错 / Xoff 太高	核对 cable length、MTU、速率、headroom；看 `no-buffer-discard`。	这是缓冲问题，不是 CC 参数问题。
CNP 计数不增长	NP 未启用 / CNP 被丢 / DSCP 映射错	查 NP enable、CNP 队列、交换机 SP6 映射。	CNP 被 pause 也会表现为“不增长”。
降速后恢复很慢	AI/HAI 太小 / RPG_TIME_RESET 太大 / CLAMP 过保守	小幅提高 AI/HAI 或降低 TIME_RESET；一次只改一个。	恢复太快会再次拥塞，形成振荡。
时延抖动大	ECN 阈值过晚 / PFC 频繁 / 缓冲占用高	看 buffer max usage、PFC pause duration、CNP 延迟。	先定位是缓冲还是 CC，不要盲调 α。

5.5 不要这样调

- 不要同时改 `DCE_TCP_G`、`RPG_GD`、`RPG_AI_RATE`、`RPG_HAI_RATE`；出了问题无法归因。
- 不要把 `RPG_MIN_RATE` 设得很低来“保护吞吐”；它可能让拥塞流长期占着少量带宽，恢复更慢。
- 不要把 `RPG_HAI_RATE` 设得很大来“快速恢复”；突发会再次打满队列，形成锯齿。
- 不要用 `RATE_TO_SET_ON_FIRST_CNP` 做“快速止血”；它绕过 α 的渐进降速，容易过冲。
- 不要在生产环境用 `mlxconfig reset` 回滚；它会重置所有固件参数。用备份的逐项值恢复。

5.6 A/B 测试方法

每次只改变一个参数，保持拓扑、MTU、线缆、应用并发、消息大小不变。每组至少跑 3 次，取中位数；同时记录交换机侧 ECN 标记率、PFC pause、buffer max usage，以及主机侧吞吐、P99 时延、`out_of_sequence`、重传。只有“吞吐/时延改善，且 PFC/丢包没有恶化”才算有效。

```
# 记录一次基线（示例）
ethtool -S $IF > baseline_$(date +%F_%H%M).txt
mlnx_qos -i $IF > baseline_qos_$(date +%F_%H%M).txt
cat /sys/class/net/$IF/ecn/roce_rp/params/rpg_gd >> baseline_ecn.txt


# 变更后至少观察 10 分钟稳定态，再做 incast
# 不要只看单流 ib_write_bw 的峰值
```

6 PFC 流控：原理、缓冲与阈值

PFC 是 IEEE 802.1Qbb 的逐优先级暂停机制。它在一条物理链路上创建 8 个虚拟链路，可以单独暂停/恢复某个优先级，从而让 RoCE 走 lossless，而普通 TCP 继续走 best-effort。[S3][S8]

6.1 PFC 的基本行为

- **逐优先级**：PFC 只暂停指定 priority，其他 priority 继续发送；这比全局 pause 精细。[S8]
- **逐跳**：Pause 是链路本地行为；上游交换机/网卡收到后停止向该链路发送，不携带端到端语义。[S8][S12]
- **默认关闭**：NVIDIA Onyx 默认在所有端口、所有优先级关闭 PFC；必须显式开启。[S8]
- **物理口限制**：Onyx 明确 PFC 只支持物理端口，不支持隧道或 vSwitch 共享的逻辑接口。[S8]
- **Xoff/Xon**：接收侧缓冲达到 Xoff 发 Pause；降到 Xon 发 Xon（恢复）。[S8][S9]
- **不是零丢包**：headroom 不足、配置错误、PFC 风暴时仍然会丢包。[S10]

6.2 缓冲模型：PG、TC 与 headroom

交换机的入口和出口是两套缓冲。入口按 PG（Priority Group）管理，出口按 TC（Traffic Class）管理；PFC 的 Xoff/Xon 作用在入口 PG 上，ECN 的 Kmin/Kmax 作用在出口队列上。把两者混为一谈，是很多“PFC 配了但没用”的根源。[S9]



图 2 PFC 缓冲、Xoff/Xon 与 headroom 的概念关系（根据 [S8][S9][S12] 绘制，非按比例）

概念	位置/作用	要点
Ingress PG	入口优先级组；PFC 的 reserved/headroom/Xoff/Xon 在这里。	按 priority 分组，丢包前最后一道缓冲。
Egress TC	出口流量类；ECN 的 Kmin/Kmax 在这里。	按 TC 排队，决定标记/调度。
Reserved	给某个 PG/TC 的保底缓冲，不被其他区域共享。	Onyx 要求 lossless PG 的 reserved 至少覆盖 Xoff。[S9]
Shared	按 alpha/静态阈值动态共享的缓冲。	可吸收突发，但不能保证不被别的流量占用。
Headroom	Xoff 之后仍在链路上的报文所需的额外入口缓冲。	不足 → PFC 还没来得及生效就丢包。[S9]

6.3 Headroom 估算

NVIDIA 文档明确指出：PFC 的 Xoff/Xon 阈值取决于带宽、链路时延、MTU 和分配到的缓冲大小；如果 headroom 不足，交换机会在 PFC 生效前丢包。Cumulus 文档还指出，PFC 缓冲计算是 IEEE 802.1Q-2012 定义的复杂问题，cable length 配错会导致“缓冲浪费/过早拥塞”或“PFC 还没触发就丢包”。[S9][S12]

下面是一个只用于量级校验的工程公式，不是 NVIDIA 的交换机计算公式：

```
H_req ≈ 2 × C × T_prop + C × T_react + 2 × MTU

C       = 线速 (byte/s) , 100GbE = 12.5e9 B/s
T_prop  = 线缆长度 / 传播速度，光纤/铜缆约 2e8 m/s
T_react = Pause 帧序列化 + PHY/MAC + 发送端响应（建议实测或取保守值）
2×MTU   = 报文粒度/量化余量

示例（仅说明量级）：
100GbE、100 m、MTU 4200 B、T_react≈1 µs
2×C×T_prop = 12,500 B
C×T_react  = 12,500 B
2×MTU      = 8,400 B
合计约 33.4 KB；加 30% 余量约 43 KB
```

> **不要用这个公式替代厂商计算**
>
> 真实交换机按 cell、端口、PG、共享池和 ASIC 内部延迟计算 headroom；上面的公式只用来判断“自动计算的 headroom 是否在同一量级”。如果交换机自动计算可用，优先使用自动计算；Cumulus 文档也建议不要随意改默认阈值，让 NOS 动态配置。[S12]

6.4 Xoff/Xon 设计规则

- **reserved ≥ Xoff**：Onyx 明确要求 lossless PG 的 reserved 至少等于 Xoff，否则水线没有足够的实体缓冲承接。[S9]
- **Xon < Xoff，并留回差**：两者太近会频繁 pause/unpause，形成抖动；太远会长时间不恢复，吞吐受损。
- **Xoff 不能吃掉 headroom**：headroom 是 Xoff 之后的在途报文空间，不能把 reserved 全部用到 Xoff。
- **cable length 要填真实值**：填短了会低估在途报文，导致丢包；填长了会浪费缓冲、过早拥塞。[S12]
- **MTU 要一致**：路径 MTU 变大，headroom 需求也变大；不要让 RoCE 流量在途中被分片。
- **先自动、后手动**：能自动计算就不要手调；必须手调时，用 `no-buffer-discard`、`buffer max usage`、PFC pause duration 做闭环。

6.5 PFC watchdog 与 PFC storm

PFC 的副作用是反压会沿路径传播。如果某个接收端长期不 drain，缓冲区会一层层填满，Pause 帧会扩散成 PFC storm，严重时大面积停传。NVIDIA 用两类机制止损：交换机侧的 PFC watchdog，以及主机侧的 PFC stall prevention。[S8][S12][S3]

机制	行为	关键参数/计数器
交换机 PFC watchdog	检测某个 TC 持续处于 pause 状态；超过 polling/robustness 阈值后，停止处理该 TC 的 Pause，并丢弃新到该队列的报文，直到风暴解除。	Cumulus 默认 polling 100 ms、robustness 3；Onyx 用 `pfc-wd` 开启。[S12][S8]
主机 PFC stall prevention	本端持续发送 Pause 超过超时后，停止发送 Pause，避免把整条链路拖死。	默认 8 s；`auto` 模式为 100 ms。[S3]
主机计数器	`tx_pause_storm_warning_events`、`tx_pause_storm_error_events`。	warning 是预警；error 表示已超过超时并采取动作。[S3]
PFC 逐优先级计数器	`prioN_tx_pause`、`prioN_rx_pause`、`prioN_tx_pause_duration`、`prioN_rx_pause_duration`。	tx=本端发出的 Pause；rx=本端收到的 Pause。[S3]

> **8 秒默认值偏长**
>
> 主机 stall prevention 默认 8 s，意味着最坏情况下 Pause 会持续很久；`auto` 把它缩短到 100 ms。是否切到 `auto` 要评估误触发风险：太短可能在正常反压时误停 Pause，导致丢包。建议先在实验环境验证，再决定是否作为生产默认。[S3]

6.6 PFC 的代价

- **缓冲成本**：每个 lossless priority 都要预留 headroom/reserved；端口越多、速率越高、线缆越长，成本越大。
- **HOL**：PFC 只隔离 priority，不隔离同一 priority 内的流；一条慢流仍可能挡住同 priority 的其他流。
- **风暴风险**：一个坏接收端可以把反压传播到整片 fabric；必须配合 watchdog 和监控。
- **配置复杂度**：PFC、trust、DSCP/PCP、buffer、cable length、DCBX 必须端到端一致；任何一处错配都可能“看似开启、实际无效”。
- **不是所有场景都需要**：能容忍重传的 L3/多租户业务，lossy + ECN 往往更简单、更稳。

6.7 什么时候用 semi-lossless

Onyx 提供 semi-lossless 模式：主机到 ToR 的方向使用 PFC 吸收微突发，fabric 内部保持 lossy，不把 pause 传播到整网。它适合“边缘微突发很严重，但全网 lossless 成本和风险太高”的场景。[S10]

semi-lossless 不是“半吊子 lossless”：它不保证端到端零丢包，只保证边缘能吸收瞬时突发。业务如果要求严格零丢包，仍然要设计完整的 lossless 域。

7 端到端设计：优先级、PFC 域与 ECN 域

设计阶段只做三件事：把流量分对类、把 PFC 限制在正确的域、把 ECN/DCQCN 覆盖到整条路径。配置命令是最后一步；分类和域设计错了，命令再对也不会稳定。

7.1 设计原则

1. **一个 lossless priority 只承载一类业务**：RoCE 数据放独立 priority；不要把普通 TCP、管理流量、存储流量混进同一个 lossless class。
2. **CNP 独立且最高优先**：CNP 走 strict priority，不与 RoCE 数据共享队列；否则拥塞时 CNP 自己也被排队。
3. **PFC 域尽量靠近端点**：PFC 是逐跳反压，扩得越大，风暴影响面越大；跨 L3/WAN 不要依赖 PFC。
4. **ECN 域覆盖全路径**：所有可能成为瓶颈的交换机都要支持 ECN，并在正确的 TC 上标记；否则 DCQCN 看不到瓶颈。
5. **PFC 先于丢包、晚于 ECN**：目标是 ECN 先触发、PFC 兜底；但两者作用在不同缓冲，不能只比较数值，要用计数器验证。
6. **缓冲按最坏情况设计**：最大 MTU、最长线缆、最高速率、最多 lossless priority；不要按平均值算 headroom。
7. **可观测**：每个 priority 的 PFC、ECN、丢包、缓冲使用率都能被采集；否则无法调优。
8. **可回滚**：每次只改一个平面（分类/PFC/ECN/缓冲），保留上一版配置。

7.2 优先级与一致性矩阵

下面是 NVIDIA 文档中常见的 RoCE 默认规划：RoCE 数据 priority 3、DSCP 26；CNP priority 6、DSCP 48。它不是协议强制值，但作为起点最容易与 NVIDIA 的默认 profile 对齐。

流量	标记（典型）	SP	TC	PFC	ECN	说明
RoCEv2 数据	DSCP 26 / PCP 3	3	3	开（仅此 priority）	开	lossless 主业务
CNP	DSCP 48 / PCP 6	6	6	不开	默认不启用	strict，不应被 pause
普通 TCP/管理	DSCP 0 / PCP 0	0	0	不开	可开	lossy/best effort

一致性矩阵比单条命令重要。下面任何一行不匹配，都可能表现为“PFC 配了但不生效”或“ECN 标记了但 CNP 回不来”。

层	正确状态	常见错配	验证
应用	RoCE QP 设置 ToS/DSCP=26；CNP 由网卡生成	应用不设 ToS，流量落到 priority 0	用 `tcpdump -v` 看 TOS，或看交换机 ECN/PFC 计数是否增长
网卡 trust	DSCP（L3）或 PCP（L2），与 fabric 一致	trust PCP 但网络只改 DSCP	`mlnx_qos -i $IF` 看 trust；抓包看 PCP/DSCP
网卡 PFC	priority 3 = 1，其余 0	PFC 开在 priority 4	`mlnx_qos -i $IF` 看 PFC 配置
网卡 ECN	roce_rp/roce_np 的 priority 3 都 enable	只开 RP 或只开 NP	`cat .../enable/3`

层	正确状态	常见错配	验证
交换机 ingress	trust DSCP/PCP；DSCP26→SP3，DSCP48→SP6	trust L2 但只配 DSCP	`show qos` / `nv show qos`
交换机 egress	TC3 为 RoCE，TC6 为 CNP strict	CNP 和 RoCE 共用一个 TC	`show roce` / `nv show qos roce`
缓冲	PG3 lossless，headroom/Xoff/Xon 合理	PG3 仍是 lossy	`show buffers` / `nv show qos roce`

7.3 L2/PCP 还是 L3/DSCP

维度	L2 / PCP	L3 / DSCP
标记位置	VLAN 标签的 PCP（3 bit）	IP 头的 DSCP（6 bit）
交换机 trust	L2 或 both	L3 或 both
适用	同子网、裸金属、传统 L2 fabric	路由、多租户、RoCEv2 主流
前提	端到端 VLAN 标签存在	应用/QP 设置 ToS；路径设备保留 DSCP
风险	VLAN 重写/剥离导致 PCP 丢失	应用未设 ToS，流量落到默认 priority
NVIDIA 默认	Onyx 默认 trust L2；RoCE lossless 用 L3	Cumulus RoCE 默认 trust pcp,dscp

选择建议：能端到端控制应用 ToS、且 fabric 是 L3 的，优先 DSCP；只能在 L2 内闭环、且 VLAN 可控的，用 PCP。不要在同一 lossless class 里同时依赖 PCP 和 DSCP 两套映射，除非你已经验证两者一致。

> **SR-IOV 的顺序**
>
> MLNX_OFED 文档明确：trust state 应在启用 SR-IOV 之前设置，以便传播到 VF。先在 PF 上把 trust/PFC 配好，再开 VF；否则 VF 可能看不到正确的优先级映射。[S2]

7.4 PFC 域与 ECN 域

```
主机 A ──PFC── Leaf1 ──PFC── Spine ──PFC── Leaf2 ──PFC── 主机 B
   |_____________________ PFC：逐跳、L2、可扩散 _____________________|
   |_____________________ ECN/DCQCN：端到端、L3 _____________________|

原则：
- PFC 只解决“这一跳的入口缓冲快满了”；不解决“整条路径谁该降速”。
- ECN 标记可以跨 L3；CNP 从接收端回到发送端，必须被优先转发。
- 跨 WAN/跨租户边界不要依赖 PFC；那里用 ECN + 重传/应用限速。
```

- **PFC 域**：从主机网卡到 ToR，或到 leaf 的 lossless 边界；域内每一跳都要开 PFC、配好缓冲。
- **ECN 域**：所有可能拥塞的 L3 设备；至少覆盖 leaf/spine 的 RoCE TC。
- **边界设备**：如果 PFC 只到 ToR，ToR 到 spine 的链路按 lossy 设计，必须确保 ECN 能吸收溢出；否则会在边界丢包。
- **CNP 路径**：CNP 从接收端回到发送端，可能经过与数据不同的路径；每条可能路径都要保证 CNP 的 DSCP/PCP 和 strict 队列。

7.5 三种部署模式

模式	机制	适用	代价/风险	依据
Lossless	PFC + ECN/DCQCN	存储、HPC、AI 训练等对丢包/重传敏感、fabric 可控的场景	配置复杂、PFC storm、缓冲成本高	[S10][S13]
Lossy	ECN/DCQCN，无 PFC	可重传、多租户、跨 L3、运维希望更简单的场景	时延/抖动、乱序、重传；拥塞严重时仍会丢包	[S10][S13]
Semi-lossless	边缘单向 PFC；fabric 保持 lossy/ECN	主机到 ToR 微突发严重、但不想把 pause 扩散到全网	不是端到端零丢包；边界仍需 ECN/缓冲	[S10]

选择顺序：先问业务能否容忍重传/乱序；不能才上 lossless。不要因为"PFC 听起来更稳"就默认全闪；PFC 的运维复杂度往往高于 ECN。

7.6 带宽、超配与缓冲

- PFC/ECN 都不创造带宽。持续 2:1、4:1 超配下的 incast，靠调阈值只能缓解，不能根治；先做流量工程/拥塞源控制。
- 缓冲不是越大越好：大缓冲会抬高排队时延，也会让 ECN 反应变慢；按 BDP + 突发 + MTU 设计，而不是"能给多少给多少"。
- lossless 缓冲要按"最坏端口组合"算：多个 ingress 同时打一个 egress 时，headroom 和 shared pool 都会被放大。
- 如果 PFC pause 长期很高但 ECN 标记很低，说明 ECN 没有承担主要工作；先调 ECN，而不是继续加缓冲。
- 如果 `no-buffer-discard` 在增长，说明 lossless 已经破了；先查 cable length/headroom/Xoff，再谈 CC 参数。

7.7 两个参考场景

场景 A：单 ToR、小规模 lossless RoCE

- 主机双口接同一 ToR（或双 ToR，按 MC-LAG/MLAG 设计），ToR 上 RoCE priority 3 开 PFC，CNP priority 6 strict。
- ToR 的 ECN 阈值按默认 RoCE profile 起步；用 4:1/8:1 incast 验证 ECN 标记和 PFC pause 都在可控范围。
- 主机 `mlnx_qos --pfc 0,0,0,1,0,0,0,0`，`--trust=dscp`，`--cable_len` 填实际值；ECN RP/NP priority 3 都开。
- 适合：小规模存储、单租户 HPC；不适合：跨 WAN、强多租户。

场景 B：Leaf-Spine、RoCEv2 over L3

- 主机到 leaf 可以 lossless（PFC 只到 leaf），leaf-spine 走 ECN；所有 leaf/spine 的 RoCE TC 都开 ECN。
- CNP 的 DSCP 48 在全路径映射到 strict TC6；确保 spine 不会把 CNP 排到数据后面。

- 如果业务能重传，优先 lossy + ECN，避免 PFC 跨 spine 扩散；如果必须 lossless，PFC 域要显式限定，并开 watchdog。
- 适合：AI/HPC 多级 fabric；需要严格的 buffer/ECN 调优和监控。

7.8 反模式

- 所有 priority 都开 PFC，“反正不丢包”；结果普通 TCP 也会反压，风暴影响面最大。
- PFC 开在 priority 4，ECN/应用用 priority 3；计数器全是 0，误以为“没拥塞”。
- CNP 和 RoCE 数据共用一个 TC；拥塞时 CNP 被数据挡住，DCQCN 反应迟滞。
- 只在主机开 PFC，交换机没开；主机发 Pause，交换机不理会或不对称。
- cable length 随便填 1 m；高估缓冲、低估在途，PFC 还没生效就丢包。
- 把 `no-buffer-discard` 当成“正常重传”；lossless 设计里它应该是 0 或接近 0。
- 在生产环境用 `mlxconfig reset` 回滚；把所有固件参数一起清掉。
- 不记录基线，调参后只看吞吐峰值；P99 时延和 PFC 风暴被忽略。

8 实施步骤：从基线到上线

这一章给出一条可以照着执行的路径。命令中的 `$IF`、`$DEV`、`$P` 是占位符；执行前先替换成实际接口、MST 设备和优先级。不同固件/驱动的参数名可能带 `_P1/_P2` 后缀，先 query 再 set。

8.1 Step 0：盘点与备份

```
# 1) 确认网卡、驱动、固件
lspci -d 15b3: -nn
ethtool -i $IF
ofed_info -s
mlxfwmanager --query


# 2) 找到 MST 设备
mst start
mst status -v


# 3) 备份当前配置（非常重要）
mkdir -p /root/roce-baseline
mlxconfig -d $DEV query > /root/roce-baseline/mlxconfig.before.txt
mlnx_qos -i $IF > /root/roce-baseline/mlnx_qos.before.txt
ethtool -S $IF > /root/roce-baseline/ethtool.before.txt
cat /sys/class/net/$IF/ecn/roce_rp/enable/$P \
  > /root/roce-baseline/ecn_rp_enable.before.txt 2>/dev/null || true
```

先确认端口是 Ethernet

VPI 卡可能当前是 IB 模式。`mlxconfig query` 看 `LINK_TYPE_P1/P2`；如果是 IB，先确认业务允许切换到 Ethernet，并预留重启/中断窗口。不要把 Ethernet 的 PFC 命令套到 IB 端口。

8.2 Step 1：固件侧（持久化）

固件侧主要设置三件事：哪些 priority 启用 DCQCN、CNP 的 DSCP/PCP、以及（必要时）端口链路类型。`mlxconfig` 的配置跨重启保留，修改后需要重启才能生效。[S14]

```
# 1) 先看参数名和当前值
mlxconfig -d $DEV query | grep -E 'ROCE_CC|CNP_|LINK_TYPE'


# 2) 只对 priority 3 启用 DCQCN（按 8 位掩码理解 bit3=8；先 query 确认）
#    如果 query 显示参数带端口后缀，则用 ROCE_CC_PRIO_MASK_P1 / CNP_DSCP_P1 ...
mlxconfig -d $DEV -y set \
  ROCE_CC_PRIO_MASK=8 \
  CNP_DSCP=48 \
  CNP_802P_PRIO=6


# 3) 复核 Next Boot 值
mlxconfig -d $DEV query | grep -E 'ROCE_CC|CNP_'


# 4) 重启（官方要求）
reboot
```

- `ROCE_CC_PRIO_MASK=255` 表示 8 个 priority 全开，是 Network Operator 的 RoCE 优化默认；只承载一个 RoCE priority 时，按 8 位掩码理解可用 8（bit3），但写入前务必用 `mlxconfig query` 确认参数名和描述。[S15]
- `CNP_DSCP=48`、`CNP_802P_PRIO=6` 是 NVIDIA 默认；如果你的 fabric 把 CNP 映射到别的 SP/TC，必须同步改，不能只改一半。[S6]
- 固件参数是持久化的；这正是它与 `mlnx_qos`/sysfs 的区别。[S14][S15]
- 如果只是改 CNP 的 DSCP/PCP，不需要动 `LINK_TYPE`；不要为了“重置”而改链路类型。

8.3 Step 2：交换机侧

交换机侧要同时配置：trust、PFC、ECN、CNP 的 strict 队列、lossless buffer。NVIDIA Onyx 和 Cumulus Linux 都有 RoCE 一键 profile；先用 profile 建立基线，再做局部调优。

Onyx 示例

```
# 进入 config 模式
configure terminal


# 一键 lossless RoCE: PFC priority 3 + ECN + buffer + CNP strict
roce lossless


# 核对默认值（不同版本输出可能不同）
show roce
show interfaces ethernet 1/1 counters roce
show interfaces ethernet 1/1 counters pfc prio 3
```

如果不用一键 profile，至少显式配置 PFC:

```
dcb priority-flow-control enable force
dcb priority-flow-control priority 3 enable
interface ethernet 1/1 dcb priority-flow-control mode on force
```

Onyx 的 `roce` 命令可能引起接口 toggle 和瞬时流量损失；变更前确认维护窗口。[S11]

Cumulus Linux 示例

```
# lossless RoCE (默认模式)
nv set qos roce mode lossless
nv set qos pfc default-global switch-priority 3
nv set qos pfc default-global cable-length 100
nv config apply


# 核对
nv show qos roce
nv show interface swp1 qos roce counters
```

如果只想用 ECN、不用 PFC:

```
nv set qos roce mode lossy
nv config apply
```

> **不要混用两套 NOS 命令**
>
> Onyx 与 Cumulus 的语法、默认值、对象模型不同；本文把它们并列只是为了说明“同一机制在不同 NOS 上怎么落”。生产环境只选你实际使用的那一套，不要把 `dcb priority-flow-control` 和 `nv set qos` 混着敲。

8.4 Step 3：主机侧（运行时）

主机侧要配置 trust、PFC priority、cable length、ECN RP/NP。PFC 和 trust 是运行时配置，通常不会跨重启保留；需要纳入启动脚本。[S15]

```
IF=ens1f0np0
P=3


# 1) DCBX 控制权：本地静态配置用 OS 控制；如果交换机用 DCBX 下发，改用 fw 并不要同时用 lldptool
mlnx_qos -i $IF --dcbx=os


# 2) trust：L3 用 dscp；L2 用 pcp
mlnx_qos -i $IF --trust=dscp


# 3) PFC：只开 priority 3
mlnx_qos -i $IF --pfc 0,0,0,1,0,0,0,0


# 4) cable length：按实际线缆填写（单位以工具帮助为准）
mlnx_qos -i $IF --cable_len=100


# 5) 可选：显式 DSCP→priority 映射，确保 26→3、48→6
mlnx_qos -i $IF --dscp2prio set,26,3
mlnx_qos -i $IF --dscp2prio set,48,6


# 6) ECN RP/NP：priority 3 启用
echo 1 > /sys/class/net/$IF/ecn/roce_np/enable/$P
echo 1 > /sys/class/net/$IF/ecn/roce_rp/enable/$P


# 7) 核对
mlnx_qos -i $IF
```

- `--pfc` 的 8 个值对应 priority 0–7；第 4 个值是 priority 3。不要照抄文档里 priority 4 的示例。
- `--cable_len` 影响主机侧 Xoff/Xon 阈值；填错会导致缓冲浪费或丢包。[S2]
- `--trust=dscp` 是 L3 方案的起点；如果 fabric 是纯 L2/PCP，用 `--trust=pcp`，并确保 VLAN 标签存在。
- 如果 DCBX 是 `fw` 控制，`mlnx_qos` 的修改可能被固件覆盖；先确认 `mlnx_qos -i $IF` 的 DCBX mode。[S2]

8.5 Step 4：应用侧标记

如果应用不设置 ToS/DSCP，RoCE 流量可能落到 priority 0，PFC/ECN 都不会按预期工作。RoCE 应用通过 RDMA-CM 的 `RDMA_OPTION_ID_TOS` 设置 ToS；MLNX_OFED 文档特别提醒：RoCE 只有 4 个预定义 ToS 值可用于 QoS 映射。[S2]

- 确认应用/中间件把 RoCE 流量标成 DSCP 26（或你的 fabric 规划值）。
- 确认 CNP 由网卡生成，不经过应用；不要把 CNP 和业务流量混在一个 QP/priority。
- 用 `tcpdump -v` 或交换机计数器验证标记；不要只信应用配置。
- 如果使用 SR-IOV，先在 PF 上设置 trust，再启用 VF。[S2]

8.6 Step 5：开机自动应用

把运行时配置做成 systemd oneshot、Ansible playbook 或 Network Operator 的 NicConfigurationTemplate。不要依赖"上次手动敲过"。下面的 unit 只是模板；ExecStart 需要替换成你的接口和参数。

```
# /etc/systemd/system/roce-qos.service
[Unit]
Description=Apply RoCE PFC/trust/ECN runtime settings
After=network-online.target
Wants=network-online.target


[Service]
Type=oneshot
ExecStart=/usr/sbin/mlnx_qos -i ens1f0np0 --trust=dscp
ExecStart=/usr/sbin/mlnx_qos -i ens1f0np0 --pfc 0,0,0,1,0,0,0,0
ExecStart=/usr/sbin/mlnx_qos -i ens1f0np0 --cable_len=100
ExecStart=/bin/sh -c 'echo 1 > /sys/class/net/ens1f0np0/ecn/roce_np/enable/3'
ExecStart=/bin/sh -c 'echo 1 > /sys/class/net/ens1f0np0/ecn/roce_rp/enable/3'
RemainAfterExit=yes


[Install]
WantedBy=multi-user.target
```

> **Network Operator 已经做了这件事**
>
> 如果你用 NVIDIA Network Operator 的 `roceOptimized`，它会设置 `ROCE_CC_PRIO_MASK=255`、CNP DSCP/PCP，并在每个 PF 上配置 PFC priority 3、trust dscp、ToS 0；文档明确这些运行时配置是非持久的，需要在每次启动后应用。不要和手写 systemd 重复配置，选一个 authority。[S15]

8.7 Step 6：变更顺序与停机

#	阶段	动作	影响
1	固件参数	mlxconfig + reboot	需要重启；业务中断
2	交换机 RoCE profile	roce lossless / nv set qos roce	可能 toggle 接口；业务中断
3	交换机 buffer/ECN 微调	按厂商命令	可能瞬时丢包；维护窗口
4	主机 trust/PFC/cable_len	mlnx_qos	可能短暂断流；逐台滚动
5	主机 ECN sysfs	echo enable/params	可能短暂降速；逐台滚动
6	应用 ToS	应用/中间件配置	按应用灰度

每一阶段结束后都做一次最小验证（PFC 配置、ECN enable、CNP 计数），不要等全部配完再排错。

9 验证、验收与性能测试

验证的目标不是“命令敲成功了”，而是“拥塞时 PFC/ECN 按预期动作，业务指标达标”。至少要做单流、incast、故障/风暴、重启持久化四类测试。

9.1 测试拓扑

- 两台主机 + 一台交换机，链路速率/MTU/线缆长度与生产一致；主机双口建议接同一 ToR 或双 ToR，按生产拓扑。
- RoCEv2 GID 用 `show_gids` 确认；`ib_write_bw -d mlx5_0 -x <gid>` 指定 RoCEv2 GID。
- 至少 4 个客户端打 1 个服务端做 incast；如果生产有 8:1、16:1，实验室也要覆盖。
- 交换机镜像/计数器和主机 `ethtool -S` 同时采集；否则无法判断 PFC 和 ECN 谁先动作。

9.2 验收标准

项目	通过标准（示例，按业务调整）	级别
PFC 配置	`mlnx_qos -i $IF` 显示 priority 3 = 1，其余 0；交换机 `show dcb priority-flow-control` oper=Enabled	必选
ECN 配置	RP/NP priority 3 enable=1；交换机 `show roce` ECN 在 TC3	必选
CNP 路径	CNP DSCP/PCP 与交换机映射一致；CNP 走 strict TC6	必选
单流吞吐	达到线速的约定比例（按业务 SLO 定义）	必选
incast 吞吐	无持续 PFC pause 风暴；吞吐随并发下降但可恢复	必选
丢包	lossless priority 的 `no-buffer-discard` 为 0 或接近 0	必选
时延	P99 在 SLO 内；无持续毫秒级尖峰	必选
风暴防护	PFC watchdog 开启；`tx_pause_storm_error_events` 不增长	必选
重启持久化	固件参数保留；运行时配置由启动项自动恢复	必选
回滚	按第 11 章能在维护窗口内恢复	必选

9.3 主机侧核对

```
IF=ens1f0np0
P=3

# PFC / trust / cable length
mlnx_qos -i $IF


# PFC 计数器（只看 priority 3）
ethtool -S $IF | grep -E "prio${P}_(rx|tx)_pause|pause_storm"

# ECN enable
cat /sys/class/net/$IF/ecn/roce_rp/enable/$P
cat /sys/class/net/$IF/ecn/roce_np/enable/$P


# ECN 参数
for f in rpg_gd rpg_ai_rate rpg_hai_rate rpg_min_rate; do
  printf "%s=" "$f"; cat /sys/class/net/$IF/ecn/roce_rp/params/$f
done


# RoCE 计数器（sysfs；不同驱动/固件名称可能不同，先 ls）
ls /sys/class/infiniband/mlx5_0/ports/1/hw_counters/
```

`ethtool -S` 的 pause 计数器语义：`tx_pause` 是本端发出的 Pause（本端接收侧拥塞），`rx_pause` 是本端收到的 Pause（对端让本端减速）。不要把两者看反。[S3]

9.4 交换机侧核对

Onyx

```
show roce
show interfaces ethernet 1/1 counters roce
show interfaces ethernet 1/1 counters pfc prio 3
show dcb priority-flow-control interface ethernet 1/1
```

重点看：ECN marked packets、RoCE PFC pause packets/duration、no buffer discard、buffer max usage。`show roce` 还会给出 Min/Max、PFC priority、TC/ETS 映射。[S11]

Cumulus Linux

```
nv show qos roce
nv show interface swp1 qos roce status
nv show interface swp1 qos roce counters
nv show interface swp1 qos pfc-watchdog
```

重点看：pfc-priority、rx/tx enabled、congestion-control min/max、ECN marked、pause packets、no-buffer-discard、buffer max usage。[S13]

9.5 流量测试

1. **单流基线**：`ib_write_bw` 单 QP，确认 GID、MTU、速率、FEC 正常；记录吞吐/时延。
2. **并发基线**：多 QP/多进程，但不过载；确认没有异常 PFC/ECN。
3. **incast**：4:1、8:1 多打一，持续 10 分钟；观察 ECN 标记、CNP、PFC pause、buffer max usage、重传。
4. **降速/恢复**：人为制造拥塞后停止，确认 RP 能恢复；不要只看“降下去”，要看“能回来且不振荡”。

5. **PFC 负向测试（仅实验室）**：让接收端暂停 drain 或注入 pause，验证 watchdog/ stall prevention 能止损；绝不在生产做。
6. **重启测试**：重启主机/交换机，确认固件参数保留、运行时配置由启动项恢复。

不要用 `ping` 验证 RoCE 拥塞控制；它不走 RDMA QP，也不产生 CNP。必须用 RDMA 流量（`ib_write_bw`/`ib_read_lat` 等）和交换机 RoCE 计数器。

9.6 计数器解读

现象	含义	下一步	依据
`prio3_tx_pause` 增长	本端接收侧入口拥塞，正在向对端发 Pause	看本端 ingress buffer、cable length、Xoff/headroom	[S3]
`prio3_rx_pause` 增长	对端让本端减速；本端是发送侧	看对端/交换机缓冲，不要只调本端	[S3]
`tx_pause_storm_warning_events`	Pause 持续时间超过预警水线	检查接收端是否慢 drain、是否死锁	[S3]
`tx_pause_storm_error_events`	超过超时，Pause 发送被禁用	立即止损；可能已经丢包	[S3]
switch `ECN marked packets` 高	交换机在标记，DCQCN 应降速	看 CNP 是否回得去、RP 是否 enable	[S11]
switch `no-buffer-discard` > 0	lossless 已破，缓冲不足或 PFC 未生效	查 headroom/cable/Xoff/PFC 配置	[S11]
`buffer max usage` 接近分配值	缓冲接近上限，随时可能丢包	扩容/调 pool/降超配	[S11]
`out_of_sequence`/重传增长	丢包或乱序；RoCE 在重传	查链路、PFC、ECN、MTU	[S16]

9.7 验收记录模板

项	内容
环境	网卡型号/PSID、固件、驱动、交换机 NOS、端口速率、MTU、线缆长度
配置	RoCE priority、PFC mask、ECN TC、CNP DSCP/PCP、buffer 参数
基线	单流/并发/incast 的吞吐、P99、PFC pause、ECN 标记、丢包
变更	改了什么、为什么、谁批准、何时回滚
结论	通过/有条件通过/不通过；遗留问题与责任人

10 运维监控、故障排查与应急

PFC/ECN 的故障往往不是“完全不通”，而是“吞吐掉一半”“时延尖刺”“偶尔重传”。这类问题必须靠计数器定位，不能靠猜。下面给出最小监控集、排障矩阵和三个应急 runbook。

10.1 最小监控集

指标	来源	阈值（预警 / 严重）	动作
PFC pause 速率	`prio3_tx_pause`、`prio3_rx_pause` 的增量	预警：相对基线持续升高 严重：> 基线 5 倍或持续 10 分钟	查缓冲/ECN/接收端 drain
PFC 风暴	`tx_pause_storm_warning_events`、`tx_pause_storm_error_events`	预警：warning > 0 严重：error > 0	立即止损，见 10.4
丢失	switch `no-buffer-discard`、`out_of_buffer`	预警：> 0 严重：持续增长	lossless 已破，查 headroom/cable
ECN 标记率	ECN marked / RoCE TC packets	预警：> 30% 持续 严重：> 80% 持续	ECN 过激或拥塞严重
CNP	NP 生成计数、RP 处理计数	预警：CNP 不增长 严重：ECN 高但 CNP 低	查 NP/CNP 队列/映射
缓冲	PG/TC max usage	预警：> 70% 分配 严重：> 90% 或接近上限	扩容/调 pool/降超配
重传/乱序	`out_of_sequence` 等 RoCE 重传/乱序计数器（名称以实际 `ls` 为准）	预警：相对基线升高 严重：持续升高	查丢包/链路/MTU
链路	FEC/BER、CRC、link down	预警：任何新增 严重：持续	换线/换模块/查光功率

阈值是建议起点，不是通用标准；请按业务基线调整。关键是“趋势 + 组合”：单独一个 PFC 计数高不一定有问题，PFC 高 + ECN 低 + 丢包增长才是危险组合。

10.2 排障矩阵

症状	可能原因	先看什么	处理原则
RoCE 能通但吞吐只有一半	ECN 过激、PFC 频繁、MTU/FEC、PCIe 瓶颈	看 ECN 标记率、PFC pause、`ethtool -S` 错误、`mlxlink`	先分离是网络还是主机；不要先调 CC 参数
时延周期性尖刺	PFC headroom 不足、buffer 满、CNP 延迟	看 buffer max usage、pause duration、CNP 计数	先保证不丢包，再谈降时延
PFC 配了但计数为 0	priority 不匹配、PFC 未真正 enable、DCBX 覆盖	`mlnx_qos -i`、交换机 oper 状态、抓包看 PFC	先让 PFC 真正生效，再调阈值
PFC 计数高但无丢包	ECN 阈值太高、PFC 在替 ECN 干活	看 ECN 标记率与 CNP	降低 ECN Kmin（必要时降低 Kmax），让 ECN 先动作
no-buffer-discard 增长	headroom 不足、cable length 错、Xoff 太高	看 buffer max usage、cable_len、MTU	按第 6 章重算，不要只加 Xoff
ECN 标记高但吞吐不降	RP 未 enable、CNP 没回来、priority mask 错	看 RP enable、CNP 计数、`ROCE_CC_PRIO_MASK`	先修 CNP 路径，再调阈值
CNP 计数低	NP 未 enable、CNP 被丢/被 pause、DSCP 映射错	看 NP enable、TC6 strict、DSCP 48 映射	CNP 必须独立且最高优先

症状	可能原因	先看什么	处理原则
重启后配置丢失	PFC/trust/ECN sysfs 非持久	对比重启前后 `mlnx_qos`/enable	纳入 systemd/Ansible/Network Operator
换固件后行为变化	默认值/参数名变化	对比 `mlxconfig query`、release notes	按新固件重建基线
PFC 风暴/大面积停传	接收端不 drain、缓冲连锁占满、watchdog 未开	看 storm 计数、watchdog 状态、buffer	按 10.4 止损

10.3 Runbook 1：PFC pause 持续升高

1. 确认范围：是单端口、单 priority，还是多端口/多 priority？先看 `prio3_tx_pause` 和交换机 PFC 计数。
2. 判断方向：`tx_pause` 高是本端接收侧拥塞；`rx_pause` 高是本端被对端反压。不要把方向搞反。
3. 查接收端 drain：应用是否停止读取、QP 是否 hung、CPU/内存/GPU 是否瓶颈。
4. 查缓冲：`buffer max usage` 是否接近分配值；`no-buffer-discard` 是否增长。
5. 查 ECN：如果 ECN 标记很低，说明 PFC 在替 ECN 干活；先调 ECN 阈值，让发送端降速。
6. 查线缆/MTU：cable length 是否准确、MTU 是否一致、是否有 FEC/CRC 错误。
7. 临时缓解：降低非关键流量、限制 incast 源、扩大 lossless pool；不要盲目把 Xoff 调高。
8. 如果出现 storm 计数，转 Runbook 3。

10.4 Runbook 2：ECN 标记了但吞吐不恢复

1. 确认交换机 ECN 标记在正确的 TC（RoCE TC3），不是普通 TC0。
2. 确认 NP 收到 CE 并生成 CNP：看 NP enable、CNP 计数、CNP DSCP/PCP。
3. 确认 CNP 没被丢/被 pause：CNP 应走 strict TC6；检查 PFC 是否误开在 priority 6。
4. 确认 RP 收到 CNP：看 RP enable、`ROCE_CC_PRIO_MASK` 是否覆盖 priority 3、QP 是否在该 priority。
5. 确认降速不是过激：`RPG_GD` 是否被改小、`RPG_AI_RATE`/`RPG_HAI_RATE` 是否过小、`RPG_MIN_RATE` 是否太低。
6. 确认恢复路径：CNP 停止后，AI/HAI 是否能让速率回来；如果回不来，查 `CLAMP_TGT_RATE`、`RPG_TIME_RESET`。
7. 如果 CNP 路径正常但吞吐仍低，查主机/应用瓶颈（PCIe、NUMA、QP 数、消息大小）。

10.5 Runbook 3：PFC 风暴/大面积停传

> **止损优先于根因**
> PFC 风暴会沿路径扩散，等待根因分析可能让整片 fabric 停摆。先隔离/止损，再保留现场（计数器、日志、抓包）。

1. 确认 storm：交换机 PFC watchdog 状态、`tx_pause_storm_error_events`、多端口 PFC pause 同时升高。
2. 隔离：在维护窗口内关闭问题端口/priority 的 PFC，或把该端口从 pool 中摘除；记录操作时间。

3. 保护：确认交换机 PFC watchdog 已开启；如果没有，按厂商命令开启（Onyx `pfc-wd`，Cumulus `qos pfc-watchdog`）。
4. 查接收端：应用是否 hang、QP 是否没有 post receive、GPU/存储是否停止 drain。
5. 查环路/错配：是否有 PFC 配置成环、priority 映射错、两个 lossless pool 互相反压。
6. 恢复：先恢复接收端 drain，再逐步恢复 PFC；不要一次性全网重启。
7. 复盘：补 headroom/ECN 调优、加 storm 告警、把 watchdog 纳入基线。

10.6 变更管理

- 变更前：记录基线、确认回滚、通知业务、准备维护窗口；PFC/ECN 变更可能造成瞬时丢包。
- 变更中：一次只改一个平面；每步后用最小命令验证（PFC 状态、ECN enable、CNP 计数）。
- 变更后：至少观察 24 小时；看 PFC/ECN/丢包/时延趋势，不只看峰值吞吐。
- 文档：把“为什么改、改了什么、验证结果、回滚命令”写进变更记录。

10.7 容量与扩容

PFC/ECN 调优不能替代容量规划。出现以下信号时，优先考虑扩容/改造，而不是继续调参数：

- ECN 标记率长期 > 80%，且降速后吞吐仍达不到 SLO。
- PFC pause 长期占空比高，增加缓冲也只是把问题推迟。
- incast 规模持续增长，单靠端点 CC 无法收敛。
- `no-buffer-discard` 在扩容前持续增长，说明 lossless 已经不可维持。

11 风险、限制与回滚

这一章是给变更评审看的。PFC/ECN 不是“开了就完事”的特性；它们会改变拥塞传播方式，必须带着风险和回滚方案上线。

11.1 风险登记

风险	等级	触发条件	缓解
PFC 风暴	高	接收端不 drain、缓冲连锁占满、watchdog 未开	开 watchdog、监控 storm 计数、隔离 lossless 域
优先级错配	高	应用/PFC/ECN/交换机映射不一致	用一致性矩阵逐层核对；抓包验证
headroom 不足	高	cable length/MTU/速率错配	按最坏情况计算；用 `no-buffer-discard` 验证
CNP 被丢/被 pause	高	CNP 与数据同 TC、DSCP 映射错	CNP strict TC6；不要对 CNP priority 开 PFC
ECN 调参过激	中	Kmin 太低、RPG_GD 太小、AI/HAI 太小	一次只改一个；incast 验证
运行时配置丢失	中	PFC/trust/ECN 非持久	systemd/Ansible/Network Operator；重启验收
固件/驱动差异	中	默认值、参数名、特性集合变化	升级前查 release notes；升级后重建基线
变更中断	高	RoCE 模式切换、mlxconfig 重启、PFC 关闭	维护窗口、逐台滚动、回滚预案

11.2 本文的限制

- 本文基于公开文档整理，未在读者的具体硬件/固件/业务上做实测；性能数字和阈值必须按现场基线调整。
- NVIDIA 文档会随版本变化；同一参数在不同固件上可能名称/默认值不同。
- Onyx 与 Cumulus 的默认值只是示例，不代表所有 NVIDIA 交换机/所有 NOS 版本。
- PFC 的 headroom 公式是工程校验公式，不是交换 ASIC 的精确计算公式；不能替代厂商工具。
- 本文不覆盖 InfiniBand 的 credit/IB CC、Windows/WinOF-2、非 NVIDIA 交换机的私有实现。
- 本文不构成性能承诺；PFC/ECN 不能解决带宽不足、应用设计缺陷、慢接收端等根本问题。

11.3 回滚方案

变更	回滚动作	影响
关闭 PFC	`mlnx_qos -i $IF --pfc 0,0,0,0,0,0,0,0`	可能立刻丢包；仅维护窗口
关闭 ECN	`echo 0 > .../ecn/roce_rp/enable/$P`、NP 同理	DCQCN 停止；拥塞可能转成丢包/PFC
恢复 PFC 配置	按备份的 `mlnx_qos` 输出重放	逐台执行；验证 oper 状态
恢复固件参数	按备份逐项 `mlxconfig set`，不要 `reset`	需要重启；可能中断
恢复交换机	恢复配置 checkpoint / 重新应用旧 profile	可能 toggle 接口
恢复应用 ToS	回退应用/中间件配置	按应用灰度

变更	回滚动作	影响

```
# 最小回滚示例（先确认变量）
mlnx_qos -i $IF --pfc 0,0,0,0,0,0,0,0
echo 0 > /sys/class/net/$IF/ecn/roce_rp/enable/3
echo 0 > /sys/class/net/$IF/ecn/roce_np/enable/3


# 固件参数：用变更前备份的逐项值恢复，不要直接 reset
# mlxconfig -d $DEV -y set ROCE_CC_PRIO_MASK=<old> CNP_DSCP=<old> CNP_802P_PRIO=<old>
# reboot
```

不要用 reset 做回滚

`mlxconfig reset` 会把所有固件参数恢复默认，包括 SR-IOV、链路类型、启动项等；在生产环境这是高风险操作。正确做法是变更前备份 `mlxconfig query`，回滚时逐项恢复。[S14]

11.4 停止条件

出现以下任一情况，停止变更并回滚，不要继续“再调一个参数试试”：

- lossless priority 出现持续 `no-buffer-discard`。
- PFC storm 计数增长，或交换机出现大面积 pause。
- 业务吞吐/P99 超过 SLO，且 10 分钟内无法定位。
- CNP 计数异常下降，ECN 标记高但发送端不降速。
- 重启后关键配置未恢复，且无法在窗口内修复。

12 结论与检查清单

ConnectX-6 的 RoCEv2 稳定性，不取决于某一个“神奇参数”，而取决于四件事：分类正确、PFC 域正确、ECN/CNP 闭环正确、缓冲与运维正确。把这四件事做成可验证的基线，比追求一套“最优参数”更重要。

12.1 五条结论

1. **PFC 是逐跳流控，DCQCN 是端到端拥塞控制**；两者互补，不能互相替代。[S3][S5][S8]
2. **Lossless 需要 PFC + ECN 一起设计**；只开 PFC 会把拥塞变成反压，只开 ECN 在严重 incast 下仍可能丢包。[S10][S13]
3. **NVIDIA 常见默认值是最好的起点**：RoCE priority 3 / DSCP 26、CNP 48/6、ECN 150 KB–1.5 MB、DCQCN 默认参数；先基线，再调优。[S6][S10][S12][S13]
4. **PFC 的成败在 headroom、cable length、Xoff/Xon、watchdog**；这些比“把 Xoff 调大”更重要。[S8][S9][S12]
5. **运行时配置不是持久的**；PFC/trust/ECN 要纳入启动项，固件参数用 mlxconfig 并重启。[S14][S15]

12.2 上线前检查清单

- ☐ 已确认端口是 Ethernet，VPI 卡没有停留在 IB 模式。
- ☐ 已记录固件/驱动/交换机 NOS 版本与 `mlxconfig query` 基线。
- ☐ 已确定 lossless/lossy/semi-lossless 模式，并得到业务确认。
- ☐ RoCE、CNP、普通流量使用不同 priority/TC；CNP 走 strict。
- ☐ 应用/QP 已设置正确的 ToS/DSCP；不是“默认 priority 0”。
- ☐ 主机 trust 与 fabric 的 L2/L3 方案一致。
- ☐ PFC 只开在 RoCE priority；交换机与主机两端一致。
- ☐ ECN 在正确的 TC 启用；Kmin/Kmax/Pmax 已按平台单位确认。
- ☐ CNP 的 DSCP/PCP 与交换机映射一致；CNP 不应被 PFC 暂停。
- ☐ headroom/Xoff/Xon/cable length/MTU 按最坏情况核对。
- ☐ PFC watchdog 与主机 stall prevention 已评估并配置。
- ☐ 已用 4:1/8:1 incast 验证，不只看单流。
- ☐ `no-buffer-discard`、`tx_pause_storm_*`、`out_of_sequence` 已纳入监控。
- ☐ 运行时配置已纳入 systemd/Ansible/Network Operator，并做过重启测试。
- ☐ 回滚方案已演练；没有用 `mlxconfig reset` 作为回滚手段。

12.3 下一步

- 用第 9 章的模板做一次完整基线，不要直接上生产调参。
- 把第 10 章的指标接入现有监控；没有监控就不要开 PFC。

- 把第 11 章的风险登记和回滚方案交给变更评审。
- 固件/驱动/交换机 NOS 升级后，重新核对本文的默认值与命令。

A 附录 A 命令速查

以下命令用于快速复制；执行前先替换 `$IF`、`$DEV`、`$P`。不同版本参数名可能不同，以 `--help`/`query` 为准。

A.1 主机侧

```
# 盘点
lspci -d 15b3: -nn
ethtool -i $IF
ofed_info -s
mst start && mst status -v


# 备份
mlxconfig -d $DEV query > mlxconfig.before.txt
mlnx_qos -i $IF > mlnx_qos.before.txt
ethtool -S $IF > ethtool.before.txt

# PFC / trust / cable length
mlnx_qos -i $IF --dcbx=os
mlnx_qos -i $IF --trust=dscp
mlnx_qos -i $IF --pfc 0,0,0,1,0,0,0,0
mlnx_qos -i $IF --cable_len=100
mlnx_qos -i $IF --dscp2prio set,26,3
mlnx_qos -i $IF --dscp2prio set,48,6


# ECN
echo 1 > /sys/class/net/$IF/ecn/roce_np/enable/$P
echo 1 > /sys/class/net/$IF/ecn/roce_rp/enable/$P
cat /sys/class/net/$IF/ecn/roce_rp/params/rpg_gd


# 核对
mlnx_qos -i $IF
ethtool -S $IF | grep -E "prio${P}_(rx|tx)_pause|pause_storm"
```

A.2 固件侧

```
# 查询
mlxconfig -d $DEV query | grep -E 'ROCE_CC|CNP_|LINK_TYPE'


# 只开 priority 3（按 8 位掩码理解 bit3=8；先 query 确认参数名）
# 如参数带端口后缀，用 _P1/_P2
mlxconfig -d $DEV -y set ROCE_CC_PRIO_MASK=8 CNP_DSCP=48 CNP_802P_PRIO=6


# 复核 + 重启
mlxconfig -d $DEV query | grep -E 'ROCE_CC|CNP_'
reboot
```

A.3 交换机侧

```
# Onyx
roce lossless
show roce
show interfaces ethernet 1/1 counters roce
show interfaces ethernet 1/1 counters pfc prio 3
show dcb priority-flow-control interface ethernet 1/1

# Cumulus
nv set qos roce mode lossless
nv set qos pfc default-global switch-priority 3
nv set qos pfc default-global cable-length 100
nv config apply
nv show qos roce
nv show interface swp1 qos roce counters
nv show interface swp1 qos pfc-watchdog
```

A.4 回滚

```
mlnx_qos -i $IF --pfc 0,0,0,0,0,0,0,0
echo 0 > /sys/class/net/$IF/ecn/roce_rp/enable/$P
echo 0 > /sys/class/net/$IF/ecn/roce_np/enable/$P
# 固件参数按备份逐项恢复；不要直接 mlxconfig reset
```

回滚后至少确认以下四项，再宣布恢复：

- PFC 已关闭或恢复到变更前状态；交换机侧 PFC oper 状态与主机一致。
- ECN 的 RP/NP enable 与参数已恢复；业务不再出现持续降速。
- 业务吞吐/P99 恢复；`no-buffer-discard`、`out_of_sequence` 没有继续增长。
- 记录回滚时间线、影响范围、根因和后续动作，更新变更记录。

B 附录 B DCQCN 参数总表

下表把 DOCA 3.5 文档中的参数、默认值、单位和调优含义集中在一起。默认值适用 ConnectX-4 及以后；实际值以本机 `cat`/`mlxconfig query` 为准。[S6]

参数	默认	单位/编码	说明
ROCE_CC_PRIO_MASK	Enable	8-bit mask	按 priority 启用 DCQCN；255=全开，8=priority3
DCE_TCP_G / dce_tcp_g	1019	10-bit fixed	α 更新权重；1019/1024≈0.995
DCE_TCP_RTT / dce_tcp_rtt	1	µs	α 更新周期
INITIAL_ALPHA_VALUE	1023	10-bit fixed	首个 CNP 的 α 初值
RATE_TO_SET_ON_FIRST_CNP	0	Mb/s	首个 CNP 强制速率；0=不强制
RPG_MIN_DEC_FAC	50	%	单次降速上限
RPG_MIN_RATE	1	Mb/s	QP 最低速率
RPG_GD	11	exponent	降速指数；越小越狠
RATE_REDUCE_MONITOR_PERIOD	4	µs	CNP 观察窗口
CLAMP_TGT_RATE	Disable	bool	连续 CNP 时 TargetRate 更新方式
RPG_TIME_RESET	300	µs	升速定时器
RPG_BYTE_RESET	32767	64 B units	升速字节计数器；约 2 MB
RPG_THRESHOLD	1	count	AI/HAI 前的连续触发次数
RPG_AI_RATE	5	Mb/s	AI 步长
RPG_HAI_RATE	50	Mb/s	HAI 步长
CNP_DSCP	48	0–63	CNP IP DSCP
CNP_802P_PRIO	6	0–7	CNP VLAN PCP
MIN_TIME_BETWEEN_CNPS	4	µs	CNP 最小间隔

关于 RPG_GD 的编码

DOCA 文档对 `RPG_GD` 的“定点编码”描述较特殊，但降速公式明确使用 `2^RPG_GD`，默认值为 11。不要把它当成线性的百分比；修改前先用 sysfs 读取实际值，并在实验环境验证单次降速幅度。[S6]

`RPG_BYTE_RESET` 的单位是 64 字节，32767×64 B≈2 MB；不要误读成 32 KB。`DCE_TCP_RTT` 与 `RATE_REDUCE_MONITOR_PERIOD` 在 DOCA 表中的单位是 µs，默认分别是 1 和 4。[S6]

C 附录 C 官方原文证据摘录

下表摘录支撑本文关键结论的官方原文（节选），并给出中文释义与出处。完整上下文请打开附录 D 的链接。

结论	官方原文（节选）	中文释义	出处
PFC 是按优先级暂停	"Priority Flow Control (PFC) IEEE 802.1Qbb applies pause functionality to specific classes of traffic on the Ethernet link."	PFC 把暂停作用于特定流量类，而不是整条链路。	[S3]
PFC 的 8 个虚拟链路	"PFC creates eight separate virtual links on the physical link and allows any of these links to be paused and restarted independently..."	一条物理链路上有 8 个可独立暂停/恢复的虚拟链路。	[S8]
PFC 默认关闭	"Keeps flow control disabled for all priorities on all ports by default"	默认所有端口、所有优先级都关闭流控。	[S8]
PFC 只支持物理口	"Supports flow control only on physical ports, not on logical interfaces..."	PFC 只作用于物理端口，不作用于隧道/逻辑接口。	[S8]
Lossless 不等于零丢包	"In this context, lossless does not mean that packets are absolutely never lost."	lossless 不意味着绝对不丢包。	[S10]
ECN 需要全路径支持	"This feature requires all nodes in the path ... to support ECN to ensure reliable communication."	ECN 需要路径上所有节点支持。	[S4]
DCQCN 的三角色	"The CP is typically the network switch." / "The NP is the receiving NIC." / "The RP is the sending NIC."	CP=交换机，NP=接收网卡，RP=发送网卡。	[S5]
PFC 缓冲与 cable length	"Incorrect cable length settings cause wasted buffer space ... or packet drops..."	cable length 配错会导致缓冲浪费或丢包。	[S12]
reserved 至少覆盖 Xoff	"The reserved allocation for this buffer should be at least the value of Xoff..."	lossless PG 的 reserved 至少应等于 Xoff。	[S9]
主机 stall prevention 默认 8 秒	"The stall prevention timeout is configured to 8 seconds by default. Auto mode sets ... 100 msec."	默认 8 秒；auto 为 100 ms。	[S3]
运行时配置非持久	"Configure pfc ... set trust to dscp ... Non-persistent (need to be applied after each boot)"	PFC/trust/ToS 等运行时配置需要每次启动后重新应用。	[S15]
mlxconfig 持久化	"The configuration is kept after reset." / "...reboot the system."	mlxconfig 配置跨 reset 保留，但需要重启生效。	[S14]
CNP 默认 DSCP/PCP	"CNP_DSCP ... 48" / "CNP_802P_PRIO ... 6"	CNP 默认 DSCP 48、PCP 6。	[S6]
RoCE 只有 4 个 ToS 值	"With RoCE, there can only be 4 predefined ToS values for the purpose of QoS mapping."	RoCE 的 ToS→QoS 映射只有 4 个预定义值。	[S2]
RoCEv2 需要 lossless 流控	"RoCEv2 requires flow control for lossless Ethernet."	要实现 lossless Ethernet，RoCEv2 需要流控。	[S13]

D 附录 D 参考文档与链接

以下 17 份文档是本文的事实来源；访问日期均为 2026-10-25。链接可能随 NVIDIA 文档版本更新而变化，若失效请用标题在 NVIDIA Networking Docs 中检索。

ID	文档（版本）	本文用途	链接
S1	NVIDIA ConnectX-6 Ethernet Adapter Cards User Manual — Introduction / Features and Benefits Last updated 2022-08-31	CX6 的 PFC、QCN、ETS、RoCE、QoS 能力与型号边界	官方页面
S2	NVIDIA MLNX_OFED Documentation — Quality of Service (QoS) v24.10-2.1.8.0 LTS (2024 LTS U2)	ToS→sk_prio→UP→TC 映射、trust、mlnx_qos、DCBX、cable_len	官方页面
S3	NVIDIA MLNX_OFED Documentation — Flow Control v24.10-2.1.8.0 LTS (2024 LTS U2)	PFC 配置、逐优先级计数器、PFC stall prevention、Dropless RQ	官方页面
S4	NVIDIA MLNX_OFED Documentation — Explicit Congestion Notification (ECN) v24.10-2.1.8.0 LTS (2024 LTS U2)	RoCEv2 ECN 的 sysfs 启用方式、RP/NP 算法与参数路径	官方页面
S5	NVIDIA DOCA Documentation — DCQCN CC Algorithm DOCA 3.5.0	CP/NP/RP 三角色、ECN 标记、CNP、alpha 与速率恢复阶段	官方页面
S6	NVIDIA DOCA Documentation — DCQCN CC Parameters DOCA 3.5.0	DCQCN 参数、默认值、单位、CNP DSCP/PCP 与最小 CNP 间隔	官方页面
S7	NVIDIA DOCA Documentation — Congestion Control Infrastructure DOCA 3.5.0	DCQCN 的定位、原生 CC 与可编程 CC 的边界	官方页面
S8	NVIDIA Onyx User Manual — Priority Flow Control (PFC) Onyx 3.10.4800	PFC 八个虚拟链路、默认关闭、物理口限制、Xoff/Xon、PFC watchdog	官方页面
S9	NVIDIA Onyx User Manual — Shared Buffers Onyx 3.10.4800	lossless traffic pool、PG/TC、reserved/shared、headroom、Xoff/Xon	官方页面
S10	NVIDIA Onyx User Manual — RDMA over Converged Ethernet (RoCE) Onyx 3.10.4800	RoCE lossless/semi-lossless/lossy 模式、默认优先级与 ECN 配置	官方页面
S11	NVIDIA Onyx User Manual — RoCE Commands Onyx 3.10.4800	show roce 默认值、RoCE 计数器、模式切换的流量影响	官方页面
S12	NVIDIA Cumulus Linux 5.15 — Quality of Service Cumulus Linux 5.15	PFC 缓冲计算、cable length、PFC watchdog、ECN 默认阈值	官方页面
S13	NVIDIA Cumulus Linux 5.15 — RDMA over Converged Ethernet (RoCE) Cumulus Linux 5.15	RoCE 默认配置、PFC+ECN 组合、DSCP 26/48 与优先级映射	官方页面
S14	NVIDIA Firmware Tools (MFT) — mlxconfig: Changing Device Configuration Tool / Examples MFT 4.36.0	mlxconfig 查询/设置、配置持久化、重启生效	官方页面
S15	NVIDIA Network Operator — Configuration Details (RoCE optimized) v26.10.0	ROCE_CC_PRIO_MASK=255、CNP DSCP/PCP、PFC priority 3、运行时配置非持久	官方页面
S16	NVIDIA DOCA Documentation — Ethernet Interface: RoCE Counters DOCA 2.9.2 LTS	RoCE 计数器所在的 sysfs 路径	官方页面
S17	NVIDIA Onyx User Manual — QoS Commands Onyx 3.10.4800	trust 默认值、DSCP/PCP 映射、ECN absolute threshold 的 KB 单位	官方页面

延伸阅读（NVIDIA 企业支持社区，可能需要登录）：

- Understanding RoCEv2 Congestion Management

- RDMA/RoCE Solutions
- Recommended Network Configuration Examples for RoCE Deployment

文档维护

建议在以下时机复核本文：① 固件/驱动大版本升级；② 交换机 NOS 升级；③ 新增 lossless 业务或改变超配比；④ 发生 PFC 风暴/大面积丢包后；⑤ 每季度例行。复核时至少重跑第 9 章的单流、incast、重启持久化和回滚四项。

修订记录

版本	日期	说明
v1.0	2026-10-25	初版：12 章 + 4 附录，覆盖 DCQCN/ECN/PFC 设计、配置、验收与排障。
v1.1	2026-10-25	事实核查修订：统一 Onyx/Cumulus ECN 单位表述；修正 CNP 的 ECN 默认状态；弱化 ROCE_CC_PRIO_MASK 掩码推导；修正 PFC 计数高时的 ECN 动作；删除无出处的参数/计数器名称。

免责声明

NVIDIA 文档会随固件、驱动、交换机 NOS 版本变化；同一参数在不同型号上也可能有不同默认值。本文给出的命令和数值用于建立可复现的基线，不构成对任何特定集群的性能承诺。生产变更前必须在同等固件/驱动的实验环境验证，并准备回滚方案。